

# Les reproducing kernel Hilbert spaces

Présentation du TER, supervisé par Christophe Giraud

Matthieu Denis

Université Paris Saclay

25 juin 2021

# Contexte

- $X$  un ensemble quelconque
- $H$  un espace de Hilbert de fonctions réelles sur  $X$
- $\forall x \in X$ ,  $L_x$  une forme linéaire sur  $H$  :

$$L_x : f \mapsto f(x) \quad \forall f \in H$$

## Définition : RKHS

$L_x$  est bornée sur  $H$ , i.e :

$$\forall x \in X, \exists M_x > 0, \forall f \in H \text{ t.q } |L_x(f)| := |f(x)| \leq M_x \|f\|_H$$

## Définition : Noyau / Kernel

Une fonction  $k : X \times X \rightarrow \mathbb{R}$  est un noyau si

$$\exists \phi : X \rightarrow H \text{ t.q } k(x, y) = \langle \phi(x), \phi(y) \rangle_H \quad \forall x, y \in X$$

## Définition : Noyau / Kernel

Une fonction  $k : X \times X \rightarrow \mathbb{R}$  est un noyau si

$$\exists \phi : X \rightarrow H \text{ t.q. } k(x, y) = \langle \phi(x), \phi(y) \rangle_H \quad \forall x, y \in X$$

## Définition : Noyau Reproductant / Reproducing Kernel

Une fonction  $k : X \times X \rightarrow \mathbb{R}$  est un noyau reproductant de  $H$  si  $\forall x \in X, f \in H :$

- $k(\cdot, x) \in H$
- $f(x) = \langle f, k(\cdot, x) \rangle_H$

# Noyaux classiques

- $k(x, y) := \langle x, y \rangle$
- $k(x, y) := (\alpha \langle x, y \rangle + 1)^d, \alpha \in \mathbb{R}, d \in \mathbb{N}$
- $k(x, y) := \exp(\|x - y\|^2 / (2\sigma^2)), \sigma > 0$
- $k(x, y) := \exp(\|x - y\| / \sigma), \sigma > 0$

# Résultats importants

Les  
reproducing  
kernel Hilbert  
spaces

Matthieu  
Denis

RKHS

**Propriété :**  
Noyau reproduisant  $\implies$  Noyau.

# Résultats importants

## Propriété :

Noyau reproduisant  $\implies$  Noyau.

## Théorème :

$H$  est un RKHS  $\iff \exists!$  noyau reproduisant de  $H$ .



# Résultats importants

## Propriété :

Noyau reproduisant  $\implies$  Noyau.

## Théorème :

$H$  est un RKHS  $\iff \exists!$  noyau reproduisant de  $H$ .

## Théorème de Moore-Aronszaj :

Soit  $k$  un noyau. Alors  $\exists!$  espace de Hilbert  $H$  de fonctions sur  $X$  pour lequel  $k$  est un noyau reproduisant.

# Application au ML : Le Representer Theorem

Soit  $k$  un kernel sur  $X$  et soit  $H$  son RKHS associée. Posons  $x_1, \dots, x_n \in X$  notre training sample. Regardons le problème d'optimisation suivant :

$$\min_{f \in H} J(f) := E(f(x_1), \dots, f(x_n)) + P(\|f\|_H^2)$$

Où  $P$  est une fonction croissante.

Alors si ce problème d'optimisation a (au-moins) une solution, il y a (au-moins) une solution de la forme

$$f = \sum_{i=1}^n \alpha_i \cdot k(\cdot, x_i)$$

De plus, si  $P$  est strictement croissante, alors toute solution a cette forme.

# Kernel Ridge Regression

Ici,  $J(f) := \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \|f\|_H^2$ , prenons  $k$  un kernel sur  $X$ . Le representer theorem nous dit que la solution de ce problème (sous couvert d'existence) est nécessairement de la forme

$$f = \sum_{i=1}^n \alpha_i \cdot k(\cdot, x_i)$$

# Kernel Ridge Regression

Ici,  $J(f) := \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \|f\|_H^2$ , prenons  $k$  un kernel sur  $X$ . Le represent theorem nous dit que la solution de ce problème (sous couvert d'existence) est nécessairement de la forme

$$f = \sum_{i=1}^n \alpha_i \cdot k(\cdot, x_i)$$

$$\min_{f \in H} J(f) := \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \|f\|_H^2$$

$$\iff \min_{\alpha \in \mathbb{R}^n} \sum_{i=1}^n (y_i - \sum_{j=1}^n \alpha_j \cdot k(x_i, x_j))^2 + \lambda \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j K(x_i, x_j)$$

$$\iff \min_{\alpha \in \mathbb{R}^n} \|y - K\alpha\|_2^2 + \lambda \alpha^T K \alpha \text{ avec } K_{ij} := k(x_i, x_j)$$

# SVM

Dans le cadre d'une SVM,  $J(f) := \frac{1}{n} \sum_{i=1}^n \max(0, 1 - y_i f(x_i)) + \frac{\lambda}{2} \|f\|_H^2$ . Prenons un kernel  $k$  sur  $X$ . Encore une fois, le representer theorem nous dit que la seule solution (si elle existe) est sous la forme

$$f = \sum_{i=1}^n \alpha_i \cdot k(\cdot, x_i)$$

# SVM

Dans le cadre d'une SVM,  $J(f) := \frac{1}{n} \sum_{i=1}^n \max(0, 1 - y_i f(x_i)) + \frac{\lambda}{2} \|f\|_H^2$ . Prenons un kernel  $k$  sur  $X$ . Encore une fois, le representer theorem nous dit que la seule solution (si elle existe) est sous la forme

$$f = \sum_{i=1}^n \alpha_i \cdot k(\cdot, x_i)$$

$$\min_{\alpha \in \mathbb{R}^n} \sum_{i=1}^n \max(0, 1 - y_i \sum_{j=1}^n \alpha_j \cdot k(x_i, x_j)) + \frac{\lambda}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j K(x_i, x_j)$$

# SVM

Dans le cadre d'une SVM,  $J(f) := \frac{1}{n} \sum_{i=1}^n \max(0, 1 - y_i f(x_i)) + \frac{\lambda}{2} \|f\|_H^2$ . Prenons un kernel  $k$  sur  $X$ . Encore une fois, le representor theorem nous dit que la seule solution (si elle existe) est sous la forme

$$f = \sum_{i=1}^n \alpha_i \cdot k(\cdot, x_i)$$

$$\min_{\alpha \in \mathbb{R}^n} \sum_{i=1}^n \max(0, 1 - y_i \sum_{j=1}^n \alpha_j \cdot k(x_i, x_j)) + \frac{\lambda}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j K(x_i, x_j)$$

On peut montrer que le dual de ce problème est :


$$\min_{\gamma \in \mathbb{R}^n} - \sum_{i=1}^n \gamma_i + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \gamma_i \gamma_j y_i y_j k(x_i, x_j) \text{ t.q. } 0 \leq \gamma_i \leq \frac{1}{n\lambda}, \alpha_i = y_i \gamma_i \forall i$$

# Visualisation

Les  
reproducing  
kernel Hilbert  
spaces

Matthieu  
Denis

RKHS





# Apparition des RKHS dans le cas d'un réseau de neurone simple

Les  
reproducing  
kernel Hilbert  
spaces

Matthieu  
Denis

RKHS

$\Phi : (\mathbb{R}^m \times \mathbb{R}^{m \times m} \times \mathbb{R}^m) \times \mathbb{R} \rightarrow \mathbb{R}$  combinaison d'applications linéaires, sans non linéarités intermédiaires :

$$\Phi((\beta, A, u), x) := \frac{1}{m^\alpha} \beta^T \left( \frac{1}{m^\gamma} A \right) u x$$

# Apparition des RKHS dans le cas d'un réseau de neurone simple

Les  
reproducing  
kernel Hilbert  
spaces

Matthieu  
Denis

RKHS

$\Phi : (\mathbb{R}^m \times \mathbb{R}^{m \times m} \times \mathbb{R}^m) \times \mathbb{R} \rightarrow \mathbb{R}$  combinaison d'applications linéaires, sans non linéarités intermédiaires :

$$\Phi((\beta, A, u), x) := \frac{1}{m^\alpha} \beta^T \left( \frac{1}{m^\gamma} A \right) u x$$

On initialise  $\theta^0 := (\beta^0, A^0, u^0)$  de manière standard :

$$\forall i, j \in \{1, \dots, m\}, u_i^0, A_{ij}^0, \beta_i^0 \sim_{iid} N(0, 1)$$

# Apparition des RKHS dans le cas d'un réseau de neurone simple

Posons une fonction de perte  $F : \mathbb{R} \rightarrow \mathbb{R}$  t.q  $F'(0) \neq 0$ . Lorsque  $\alpha < 1$ , on a pour  $m$  grand :

$$\|\nabla_{\beta/u/A} F(\Phi(\theta^{t+1}, x)) - \nabla_{\beta/u/A} F(\Phi(\theta^t, x))\| \ll \|\nabla_{\beta/u/A} F(\Phi(\theta^t, x))\|$$

# Apparition des RKHS dans le cas d'un réseau de neurone simple

Posons une fonction de perte  $F : \mathbb{R} \rightarrow \mathbb{R}$  t.q  $F'(0) \neq 0$ . Lorsque  $\alpha < 1$ , on a pour  $m$  grand :

$$\|\nabla_{\beta/u/A} F(\Phi(\theta^{t+1}, x)) - \nabla_{\beta/u/A} F(\Phi(\theta^t, x))\| \ll \|\nabla_{\beta/u/A} F(\Phi(\theta^t, x))\|$$

$$F(\Phi(\theta^T, x)) = F(\Phi(\theta^0, x)) + \langle \theta^T - \theta^0, \nabla_{\theta} F(\Phi(\theta^0, x)) \rangle + \mathcal{O}(m^{-1/2})$$

# Apparition des RKHS dans le cas d'un réseau de neurone simple

Posons une fonction de perte  $F : \mathbb{R} \rightarrow \mathbb{R}$  t.q  $F'(0) \neq 0$ . Lorsque  $\alpha < 1$ , on a pour  $m$  grand :

$$\|\nabla_{\beta/u/A} F(\Phi(\theta^{t+1}, x)) - \nabla_{\beta/u/A} F(\Phi(\theta^t, x))\| \ll \|\nabla_{\beta/u/A} F(\Phi(\theta^t, x))\|$$

$$F(\Phi(\theta^T, x)) = F(\Phi(\theta^0, x)) + \langle \theta^T - \theta^0, \nabla_{\theta} F(\Phi(\theta^0, x)) \rangle + \mathcal{O}(m^{-1/2})$$

On apprend donc un modèle linéaire relatif aux features  $\nabla_{\theta} F(\Phi(\theta^0, x))$ , c'est-à-dire qu'après la transformation  $x \rightarrow \nabla_{\theta} F(\Phi(\theta^0, x))$ , on est linéaire. On fait donc face à un RKHS de noyau (par définition)

$$k(x, y) = \langle \nabla_{\theta} F(\Phi(\theta^0, x)), \nabla_{\theta} F(\Phi(\theta^0, y)) \rangle \xrightarrow{LGN} \mathbb{E}[\langle \nabla_{\theta} F(\Phi(\theta^0, x)), \nabla_{\theta} F(\Phi(\theta^0, y)) \rangle]$$