


$$y = \beta^T x^L$$

$$= \beta^T \underbrace{\phi(\theta, x)}$$

$$x \xrightarrow{w'} z' = w' x \quad x^2$$

Diagram illustrating a transformation from  $x$  to  $z'$  via a linear transformation  $w'$ . The result  $z'$  is then mapped to  $x^2$  via a non-linear transformation  $\sigma$ .

$$x^L = \phi(\theta, x)$$



$\bar{\alpha} \quad \theta$  fixé

$\hookrightarrow$  RKHS

$$k(x, y) = \langle \phi(\theta, x), \phi(\theta, y) \rangle_H$$

$$x \xrightarrow{\quad} \phi(\theta, x)$$

## Objectif :

- 1) comprendre schéma initialisation standard
  - 2) voir que avec initialisation standard :  $NN = RKHS$   
associé à  $\nabla_{\Theta} \phi(\mathcal{D}_0, \kappa)$  } NTK
- $\Rightarrow$  pas de feature learning


3) voir quelle param / init. pour avoir feature learning dans NN

4?) quel gain quand il y a feature learning.  $L=1$

## Déroulé :

- 1) RKHS (lecture)  $\begin{matrix} \nearrow \text{RKHS} \\ \nearrow \text{représentant} \\ \rightarrow \text{géométrie (SVT)} \end{matrix}$
- 2) on va regarder 1 NN ultra-simple  
 $\rightarrow$  init. standard  
 $\rightarrow$  NTK pour lui  
 $\rightarrow$  généralisation du calcul.
- 3) Thm : manque cv. (Chizat & Bach)  
(à voir)
- 4) comprendre la bonne param/init dans l'exemple du 2)

Reseau jouté:  $L=2$   $x, y \in \mathbb{R}$   $\sigma(x) = x$



$$\phi(\theta, x) = \frac{1}{m} \beta^T \left( \frac{1}{m} A \right) u x$$

Annotations:  $\beta \in \mathbb{R}^m$ ,  $A \in \mathbb{R}^{m \times m}$ ,  $u \in \mathbb{R}^m$

1) Initialisation:  $u_i, A_{ij}, \beta_{ij} \stackrel{iid}{\sim} \mathcal{N}(0, 1)$

a)  $\|u\|^2 \underset{m \rightarrow \infty}{\sim} ?$

b) conditionnellement à  $u$

quelle est la loi de  $\frac{1}{m} A u x$  ?

En déduire la loi de  $\frac{1}{m} A u x$

et  $\| \frac{1}{m} A u x \|^2 \underset{m \rightarrow \infty}{\sim} ?$

comment choisir  $\gamma$  ?

c) loi de  $\frac{1}{m} \beta^T x^2 \underset{cond. n}{\sim} x^2$

où  $x^2 = \frac{1}{m} A u x$

x en déduire la loi

d) comment choisir  $\alpha$  et  $\gamma$  pour

avoir  $\phi(\underbrace{(\beta, A, u)}_{=\theta}, x) \underset{m \rightarrow \infty}{\rightarrow} \begin{matrix} \neq 0 \\ \neq \pm \infty \end{matrix}$

2) Apprentissage:

a)  $\nabla_{\beta} \phi, \nabla_A \phi, \nabla_u \phi$

2) Soit  $F: \mathbb{R} \rightarrow \mathbb{R}$  avec  $F'(0) \neq 0$  et  
 $\Delta F = F(\phi(\theta', x)) - F(\phi(\theta^0, x))$

$\uparrow$  1 pas de GD de paramètre

avec l'approx.  $\hookrightarrow \theta' = \theta^0 - \eta \nabla_{\theta} F(\phi(\theta, x))$

$$\Delta F \simeq \langle \Delta \theta, \nabla_{\theta} F(\phi(\theta, x)) \rangle$$

comment choisir  $\eta$  pour avoir

$$\Delta F \nearrow \neq 0$$

$$\searrow \neq \pm \infty$$

3) quel est l'ordre de grandeur  
 de  $\Delta \beta$ ,  $\Delta A$ ,  $\Delta u$  pour le  
 choix de  $\eta$  ?

$$\underline{\Delta A} ? \rightarrow \Delta A_{ij} + \|\Delta A\|_{op}$$

$$\searrow \|\Delta A\|_F$$

Ring: poly DIA2 set 7.3  
 $\{$  donne 1 info sur  $\|A^0\|_{op}$